

Quantization and Training of Neural Networks for Efficient Integer-Arithmetic-Only Inference


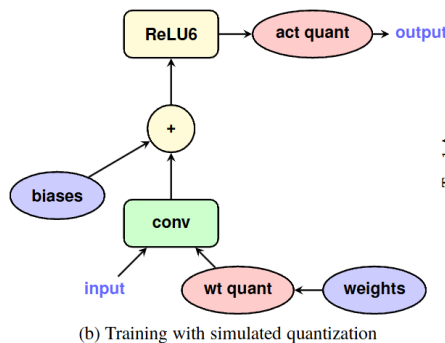

길종현(github.com/hyeon-n-off)

개요(Abstract)

딥러닝 기반의 모델의 위압적인 계산 연산량은 효율적이고 정확한 on-device inference 를 요구한다.

정수만을 사용하는(integer-only) 연산을 통해서 추론을 진행하는 양자화 방식(Quantization)을 제안한다. 이는 부동 소수점(floating point)을 사용하는 추론보다 더 효율적으로 구현할 수 있다. 또한 end-to-end 모델의 양자화 이후 정확도를 유지하기 위한 훈련 절차를 같이 설계하였다.

결과적으로, 제안된 양자화 방식은 정확도(accuracy)와 기기 내 지연시간(on-device latency) 사이의 tradeoff 를 개선할 수 있다.



1. 소개(Introduction)

현재 최신의 CNNs 는 휴대용 기기(mobile devices)에서 사용하기에 적합하지 않다. AlexNet 의 등장 이후에, 현대의 CNNs 는 주로 분류(classification) / 감지(detection) 정확도로 평가되었다. 따라서 모델 네트워크의 구조는 모델 복잡성과 계산 효율성을 고려하지 않고 발전해왔다. 반면에, 스마트폰, AR/VR 기기와 같은 휴대용 플랫폼에서 CNNs 의 성공적인 배포를 위해서는 제한된 기기 내 메모리를 수용하기 위해 작은 모델 크기와 사용자 참여(user engagement)를 유지하기 위해 낮은 지연시간을 필요로 한다. 이는 정확도 손실을 최소화하면서 모델의 크기와 CNNs 의 추론 시간을 줄이는데 초점을 맞춘 연구들이 급성장하는 분야로 이끌었다.

이 분야의 접근은 대략 두가지로 나뉜다. 첫 번째는 (MobileNet, SqueezeNet, ShuffleNet 등) 계산 / 메모리에 효율적인 연산을 활용하는 새로운 네트워크 아키텍처를 설계한다.

두 번째는 CNNs 의 가중치(weights) and/or 활성화(activations)를 32bit 부동 소수점에서 더 낮은 bit 의 표현으로 양자화한다. 현재의 많은 양자화 접근 방식(TWN, BNN, XNOR-net 등)에도 불구하고 정확도와 지연시간을 절충할 때 두 가지 측면에서 부족한 점이 존재한다.

첫 째는, 이전 방식은 합리적인 베이스라인 구조에서 평가되지 않았다. 가장 대중적인 베이스라인 구조(AlexNet, VGG 와 GoogleNet)는 정확도 향상을 위한 구조 때문에 모두 과도하게 매개변수화(over-parameterized)된다. 따라서 이러한 구조들은 쉽게 압축할 수 있기에, 이러한 아키텍처에 대한 양자화 실험은 진지한 연구라기보다는 단순한 개념 증명 수준에 불과하다. (의미 있는 실험이 아니다.)

대신, 더 의미 있는 실험은 MobileNet 과 같이 이미 효율적인 tradeoff 를 가진 모델 구조를 양자화하는 것이 될 것이다.

둘 째는, 많은 양자화 접근들은 실제 하드웨어에서의 검증 가능한 효율 향상을 보여주지 않는다. 오직 가중치만을 양자화하는 접근들은 주로 기기 내의 저장(on-device 환경에서 모델을 실을 수 있는 지)에 중점을 두고 계산 효율성에는 중점을 두지 않는다.

Binary, ternary, bit-shift 는 예외적으로 주목할만하다. 이 접근법들은 '0' 또는 '2'의 거듭제곱 인 가중치를 사용한다. 이는, Bit Shift 연산을 통해 곱셈을 구현할 수 있게 한다. 하지만 Bit Shift 연산은 커스텀 하드웨어에서는 효율적일 수 있지만, 기존의 multiply-add 구조 하드웨어에 이점을 제공하기는 어렵다.

더욱이 피연산자가 넓으면(the operands are wide) 곱셈 비용이 증가하며, 가중치와 활성화 값을 모두 양자화하면 비트 깊이(bit depth)가 낮아질수록 곱셈을 피해야 한다는 필요성이 줄어든다.

- 곱셈 연산의 계산 비용은 피연산자(operands)의 비트 폭(width)에 따라 달라진다.
- 피연산자의 비트 폭이 넓을수록 곱셈 연산의 계산 복잡도와 비용이 증가한다.
- 가중치(weights)와 활성화(activations)를 모두 양자화하면 비트 깊이가 낮아질수록 곱셈을 피해야 한다는 필요성이 줄어든다.
-
- 즉, 모델의 가중치와 활성화 값을 양자화하면 곱셈 연산의 복잡성이 감소하고, 낮은 비트 깊이에서도 연산 효율성이 개선된다.

특히, 이러한 접근 방식은 promised timing 성능 향상을 검증하기 위해 on-device 환경 내 측정을 제공하는 경우가 드물다. 런타임 친화적인(runtime-friendly) 접근법들은 가중치와 활성화(activations) 값을 모두 1 bit 표현으로 양자화한다. 이러한 접근법들로 곱셈과 덧셈 연산을 Bit Shift 와 Bit Count 기법으로 향상할 수 있다. 그러나, 1-bit 양자화는 자주 상당한 성능 저하를 이끄며, 모델 표현에 지나치게 엄격해야 한다.

이 논문에서는 일반적인 휴대용 하드웨어에서 MobileNets 의 정확도와 지연 시간의 tradeoff 를 향상시켜 위에 언급한 문제들을 개선해 나갈 것이다.

- 가중치와 활성화 값을 8-bit integer 로 양자화하고 편향(bias) 벡터와 같은 값에만 32-bit integer 로 양자화하는 '**Quantization scheme**'를 제공한다.
- 정수 - 산술 - 전용 하드웨어에서 효과적으로 구현가능한 '**Quantized inference framework**'를 제공한다.
- 실제 모델에서 정확도의 손실을 최소화하는 '**Quantized training framework**' 도 같이 제공한다.

이 논문은 CNNs의 훈련 속도를 가속화하기 위한 낮은 정밀도(low-precision)의 고정 소수점(fixed-point) 연산을 수행하는 *Deep learning with limited numerical precision*, x86 CPUs에서 추론 속도를 높이기 위해 8-bit의 고정 소수점을 사용한 *Improving the speed of neural networks on CPUs*을 참고하였다.

2. 양자화된 추론(Quantized Inference)

2.1 Quantization Scheme

이 섹션에서는, 일반적인 양자화 방식(Quantization Scheme), 즉 값의 비트 표현("양자화된 값"에 대해 q 로 표시)과 수학적 실수 해석("실제 값"에 대해 r 로 표시)간의 대응 관계를 설명한다.

논문의 양자화 방식은 **추론 시에는 정수 전용 산술을**, **학습 시에는 부동 소수점 산술을 사용하여** 구현되며, 두 구현 모두 서로 높은 수준의 대응 관계를 유지한다. 먼저 양자화 방식에 대한 수학적으로 엄밀한 정의를 제공하고, 정수 산술 추론과 부동 소수점 학습 모두에 이 방식을 별도로 채택함으로써 이를 달성한다.

논문의 양자화 방식의 기본 조건은 다음과 같다.

양자화된 값에 정수 전용 산술 연산을 사용하여 모든 산술의 효율적인 구현이 가능해야 한다. 이는 양자화 방식이 실수 r 와 정수 q 가 *affine mapping*이 되어야 한다는 것과 동일하다. (S 와 Z 는 상수이다.)

$$r = S(q - Z)$$

위 수식은 논문의 양자화 방식이며 **상수 S 와 Z 는 양자화 파라미터**이다. 양자화 방식은 각 활성화, 가중치 행렬마다 양자화 파라미터 **하나의 집합**을 사용한다. ; 각 행렬마다 다른 파라미터를 사용한다.

8-bit 양자화의 경우, q 는 8-bit 정수로 양자화된다. 몇몇의 행렬, 특히 편향 벡터는 32-bit 정수로 양자화된다.

Scaling 을 위한 **상수 S 는 임의의 양의 실수**이다. 이는 실수 r 과 같이 부동 소수점 값과 같이 표현된다.

2.2에서 추론 작업에서 이러한 부동 소수점 값의 표현을 피하는 방법에 대해 설명할 예정이다.

상수 Z (**zero-point**)는 양자화된 q 와 같은 자료형이며, 실제로는 실수 r 가 0 일 때 해당하는 양자화된 값 q 이다. 즉, $r = 0$ 인 경우 $q = Z$ 가 된다.

- 양자화 방식 중에는 대칭 양자화와 비대칭 양자화가 있는데, Z 가 입력의 0이 출력의 0에 매핑되도록 보장하는 대칭 양자화를 만들기 위한 장치로 보인다.

지금까지의 내용은 다음과 같이 요약된다.

```

template<typename QType> // e.g. QType=uint8
struct QuantizedBuffer {
    vector<QType> q;        // the quantized values
    float S;                // the scale
    QType Z;                // the zero-point
};

```

2.2 Integer-arithmetic-only matrix multiplication

어떻게 정수 전용 산술을 사용하여 추론을 진행하는 지에 대한 내용이다. (방정식을 사용하여 실수 계산을 양자화된 값으로 변환하는 방법과 상수 S 가 정수가 아니라도 정수 산술만을 포함하도록 설계하는 방법 등)

실수 r_1, r_2 로 이루어진 두 행렬($N \times N$)의 곱을 생각해보자. 그 곱은 $r_3 = r_1 r_2$ 로 표현된다.

각 행렬들은 r_α ($\alpha = 1, 2$ or 3) as $r_\alpha^{(i,j)}$ ($1 \leq i, j \leq N$) 로 표현되며, 해당 행렬들의 양자화 매개변수는 (S_α, Z_α) 이다.

$$r_\alpha^{(i,j)} = S_\alpha (q_\alpha^{(i,j)} - Z_\alpha) \quad (2)$$

행렬의 곱셈 법칙에 의해 다음과 같이 표현할 수 있다.

$$S_3(q_3^{(i,k)} - Z_3) = \sum_{j=1}^N S_1(q_1^{(i,j)} - Z_1) S_2(q_2^{(j,k)} - Z_2) \quad (3)$$

$$q_3^{(i,k)} = Z_3 + M \sum_{j=1}^N (q_1^{(i,j)} - Z_1) (q_2^{(j,k)} - Z_2), \left(M := \frac{S_1 S_2}{S_3} \right) \quad (4), (5)$$

방정식 (4)에서 유일하게 정수가 아닌 것은 M 이다. 이는 S_1, S_2, S_3 에만 의존하는 상수로써 오프라인에서 계산이 가능하다. 논문에선 경험적으로 M 이 항상 (0,1) 구간 내에 위치한다는 사실을 발견하였다. 따라서 해당 값을 다음과 같이 정규화된 형태로써 표현할 수 있다.

$$M = 2^{-n} M_0 \quad (6)$$

여기서 M_0 는 [0.5,1) 구간에 존재하며, n 은 음수가 아닌 정수이다. 정규화된 M_0 은 이제 고정 소수점 숫자로 표현되는데 적합하다. (하드웨어에 따라 int16 이나 int32 로 저장할 수 있다.) 예를 들어 int32 를 사용하는 경우 M_0 를 $2^{31} M_0$ 으로 표현하고 이를 정수로써 처리한다.

따라서 M_0 에 의한 곱셈은 고정 소수점 곱셈으로 구현될 수 있다.

- 스케일링 계수 M :

$$\text{만약 } S_1 = 0.1, S_2 = 0.2, S_3 = 0.05 \text{ 라면 } M = \frac{0.1 \times 0.2}{0.05} = 0.4$$

- M 의 표현:

$$M = 0.4 = 2^{-1} \times 0.8, \text{ 여기서 } n = 1, M_0 = 0.8$$

2.3 Efficient handling of zero-points

(4)번 방정식의 평가를 효율적으로 구현하기 위해서 $2N^3$ 번의 뺄셈을 수행하거나, 곱셈의 피연산자를 8-bit 에서 16-bit 로 확장할 필요 없이 먼저 (4)번 방정식에서 곱셈을 분배함으로써 다음과 같이 재작성할 수 있다.

$$q_3^{(i,k)} = Z_3 + M \left(NZ_1Z_2 - Z_1a_2^{(k)} - Z_2\bar{a}_1^{(i)} + \sum_{j=1}^N q_1^{(i,j)} q_2^{(j,k)} \right) \quad (7)$$

$$a_2^{(k)} := \sum_{j=1}^N q_2^{(j,k)}, \quad \bar{a}_1^{(i)} := \sum_{j=1}^N q_1^{(i,j)} \quad (8)$$

수식 (7) 유도:

수식 (4)의 곱셈 부분을 분배 법칙으로 전개합니다:

$$(q_1^{(i,j)} - Z_1)(q_2^{(j,k)} - Z_2) = q_1^{(i,j)} q_2^{(j,k)} - Z_1 q_2^{(j,k)} - Z_2 q_1^{(i,j)} + Z_1 Z_2$$

이를 $\sum_{j=1}^N$ 에 대입하면:

$$\sum_{j=1}^N (q_1^{(i,j)} - Z_1)(q_2^{(j,k)} - Z_2) = \sum_{j=1}^N q_1^{(i,j)} q_2^{(j,k)} - Z_1 \sum_{j=1}^N q_2^{(j,k)} - Z_2 \sum_{j=1}^N q_1^{(i,j)} + N Z_1 Z_2$$

이 식을 수식 (4)에 대입하면:

$$q_3^{(i,k)} = Z_3 + M \left(N Z_1 Z_2 - Z_1 a_2^{(k)} - Z_2 \bar{a}_1^{(i)} + \sum_{j=1}^N q_1^{(i,j)} q_2^{(j,k)} \right)$$

여기서:

- $a_2^{(k)} := \sum_{j=1}^N q_2^{(j,k)}$ (열 방향의 합)
 - $\bar{a}_1^{(i)} := \sum_{j=1}^N q_1^{(i,j)}$ (행 방향의 합)
-

수식 (7):

$$q_3^{(i,k)} = Z_3 + M \left(N Z_1 Z_2 - Z_1 a_2^{(k)} - Z_2 \bar{a}_1^{(i)} + \sum_{j=1}^N q_1^{(i,j)} q_2^{(j,k)} \right)$$

구성 요소:

1. $N Z_1 Z_2$:
 - 모든 항목의 곱셈에서 zero-point의 상수 곱이 등장합니다. 이는 N 으로 스케일링됩니다.
 2. $Z_1 a_2^{(k)}$:
 - 행렬 q_2 의 열 k 방향 합산에 Z_1 을 곱한 항목입니다.
 3. $Z_2 \bar{a}_1^{(i)}$:
 - 행렬 q_1 의 행 i 방향 합산에 Z_2 를 곱한 항목입니다.
 4. $\sum_{j=1}^N q_1^{(i,j)} q_2^{(j,k)}$:
 - 실제로 양자화된 값으로 계산되는 행렬 곱입니다.
-

효율성 분석:

1. 뿔셈 횟수 감소:

- Zero-point를 미리 계산하여 $NZ_1Z_2, Z_1a_2^{(k)}, Z_2\bar{a}_1^{(i)}$ 로 분리하면 $2N^3$ 개의 뿔셈 대신 $O(N^2)$ 수준의 추가 연산만 필요합니다.

2. 정수 연산 유지:

- $q_1^{(i,j)}$ 와 $q_2^{(j,k)}$ 는 여전히 정수로 유지되므로, 곱셈 연산에서 16비트로 확장하지 않아도 됩니다.

3. 미리 계산 가능한 항목:

- $M, a_2^{(k)}, \bar{a}_1^{(i)}, NZ_1Z_2$ 는 모두 미리 계산 가능하므로 런타임 연산을 최소화할 수 있습니다.
-

2.4 Implementation of a typical fused layer

섹션 2.3 에 대한 논의를 계속 중이지만, 이제 관련된 모든 데이터 유형을 명시적으로 정의하고, 양자화된 행렬 곱셈 (7)을 수정하여 bias-addition 및 활성화 함수 평가를 직접 통합한다. 전체 레이어를 단일 작업으로 융합하는 것은 단순히 최적화가 아니다. 훈련에 사용되는 산술을 추론 코드에서도 동일하게 재현해야 하므로, 추론 코드에서 융합 연산자(fused operators)의 세분성(granularity) (8-bit 양자화 입력을 받아 8-bit 양자화 출력을 생성하는 것)은 훈련 그래프에서 **“가짜 양자화(fake quantization)”** 연산자의 배치와 일치해야 한다 (섹션 3).

- **훈련 단계의 산술:** 훈련 중에는 모델이 부동소수점 연산을 사용하면서도 양자화를 흉내 내는 방식인 Fake Quantization 을 사용한다.
 - 예를 들어, 입력 값과 가중치를 8-bit 로 제한된 범위 내에서 학습시키지만 실제 계산은 부동소수점으로 이루어진다.
 - 이는 모델이 실제 양자화된 하드웨어 환경에서의 동작을 예측할 수 있도록 도움을 준다.
- **추론 단계의 산술:** 추론 시에는 실제로 양자화된 정수값으로 연산이 이루어진다.

- 따라서 추론에서 사용하는 연산자는 훈련 중 사용된 Fake Quantization의 동작과 동일한 방식으로 구성되어야 한다.
- 일관성을 유지하지 않으면, 훈련 시 최적화된 가중치와 추론 시의 계산 방식이 달라지면서 모델의 성능이 저하될 수 있다.

ARM과 x86 CPU 구조에서 구현을 위해 `gemmlowp` 라이브러리를 사용하였다. q_1 을 가중치 행렬, q_2 를 활성화 행렬로 선택하였고, 두 행렬 모두 `uint8` 형식으로 택하였다. `uint8` 값의 곱에는 32-bit 누산기 필요하다.

$$\text{int32} += \text{uint8} * \text{uint8} \quad (10)$$

2. 왜 `uint8` 타입을 사용하는가?

- **`uint8` (unsigned 8-bit integer):**
 - 장점: 0~255의 값을 가지므로 메모리 효율적이고, 하드웨어에서 잘 지원됩니다.
 - **zero-point:** 8-bit 양자화에서는 데이터의 분포를 0~255로 조정하기 위해 zero-point를 설정합니다. 이는 데이터를 unsigned로 변환하면서 실제 값이 음수일 수도 있는 상황을 처리합니다.
 - `int8`도 사용 가능하지만, zero-point를 음수로 조정해야 하며, 이는 추가 계산을 초래할 수 있습니다.
-

3. 왜 32-bit 누산기를 사용하는가?

- q_1 과 q_2 는 각각 `uint8` 타입입니다. 따라서 두 값을 곱한 결과는 0에서 $255 \times 255 = 65,025$ 범위에 속합니다.
 - $N \times N$ 행렬 곱셈에서는 수천 개 이상의 곱셈 결과를 합산하게 됩니다.
 - 예: $N = 128$ 일 경우, 하나의 행렬 곱셈에서 최대 $128 \times 128 = 16,384$ 번의 합산이 필요합니다.
 - 8-bit나 16-bit 누산기로는 이 값을 표현할 수 없기 때문에 **32-bit** 누산기가 필요합니다.
-

4. 왜 signed int32를 사용하는가?

- 누산기 타입을 **signed** (부호 있는) 32-bit로 선택한 이유는 다음과 같습니다:
 - 양자화된 값의 특성:
가중치나 활성화 값의 zero-point를 포함한 계산에서, 중간 계산 결과가 음수가 될 가능성이 있습니다.
예를 들어, $(q_1 - Z_1)(q_2 - Z_2)$ 를 계산할 때 $q_1 < Z_1$ 이거나 $q_2 < Z_2$ 인 경우 결과가 음수가 될 수 있습니다.
 - **signed** 누산기 필요성:
이러한 음수 값을 처리하려면 unsigned 타입으로는 부족하므로 signed int32가 필요합니다.
-

5. 수식 (10)의 의미

- 수식 (10):

$$\text{int32+} = \text{uint8} \times \text{uint8}$$

- 곱셈: 두 개의 `uint8` 값이 곱해져 최대 65,025 범위의 결과를 생성합니다.
 - 누산: 이 값을 signed int32에 더해줍니다.
 - 누산기는 32-bit signed 타입이므로 중간 계산 결과가 음수로 변하거나 큰 값을 가지는 경우에도 안전하게 처리할 수 있습니다.
-

int32 형 누산기에 int32 bias 를 추가하기 위해, bias-vector 를 양자화하여 int32 를 양자화된 데이터 유형으로 사용하고, 0 을 양자화 영점 Z_{bias} 으로 사용하며, 양자화 스케일 S_{bias} 는 가중치(S_1)와 활성화의 스케일(S_2)의 곱인 누산기와 동일하다.

$$S_{bias} = S_1 S_2, \quad Z_{bias} = 0 \quad (11)$$

bias-vector 는 32-bit 값으로 양자화되지만, 신경망 파라미터 중 극히 일부에 불과하다. 또한 **bias-vector**에 대해 더 높은 정밀도를 사용하는 것은 실제 요구 사항을 충족한다. 각 bias-vector entry 가 많은 출력 활성화 값들에 더해짐에 따라 bias-vector 의 양자화 오류는 전체 bias 에 작용하는 경향이 있으며, 이는 좋은 end-to-end 신경망 정확도를 유지하기 위해 피해야 한다.

- 왜 편향 벡터(bias vector)를 32-bit 로 양자화할까?

- 편향 벡터는 네트워크에서 매우 중요한 역할을 한다. 특히 각 편향이 많은 출력 활성화 함수에 더해지기 때문에 편향 벡터 양자화 오류가 전체적인 오류를 발생시킬 수 있다.
- 양자화 오류가 0 이 아닌 평균 값을 갖는 경우, 이는 전체 네트워크 출력에 편향을 추가하게 되어 **정확도 저하를 초래**할 수 있다. 따라서, 높은 정밀도로 양자화하여 오류를 최소화하려는 목적이 있다.

- 편향(bias)과 int32 누산기의 관계

- 양자화된 편향 벡터는 int32 형식으로 양자화되어, 계산 중인 int32 누산기에 추가된다. 즉, int32 타입의 누산기에 32-bit bias 값을 추가하는 방식이다.
- 이는 양자화된 값들을 정밀하게 처리할 수 있도록 도와준다. 특히, 각 편향 값은 여러 출력 활성화 값에 추가되기 때문에, 편향 벡터의 양자화에서 발생하는 오류가 모든 출력 값에 영향을 미치지 않게 해야 한다.

down-scaling 은 수식(7)에서 M 과의 곱셈에 해당한다. 이는 정규화된 M_0 와 반올림 Bit-Shift 를 사용한 고정 소수점 곱셈으로 구현된다. 이후 $[0, 255]$ 범위로 saturating cast 를 수행하여 uint8 로 변환된다.

실제로, 양자화된 훈련 과정에서는 출력 uint8 $[0, 255]$ 범위 전체를 활용하려고 학습하는 경향이 있어, 활성화 함수는 더 이상 아무런 작업을 하지 않으며, 그 효과는 uint8 로 saturating cast 를 할 때 내포된 $[0, 255]$ 의 범위로 제한하는 동작에 포함된다.

- 범위 제한(Saturating Cast)과 활성화 함수

- 범위 제한은 범위 밖의 값을 자동으로 제한하는 방식이다. 예를 들어, uint8 형식에서 계산 결과가 256 을 초과하면 자동으로 255 로 설정되고, 0 미만이면 0 으로 설정된다.
- 이 과정은 계산 후 양자화된 출력 값을 올바른 범위 내에 넣어주기 위해 필수적이다.

- 훈련 과정에서 네트워크는 양자화된 값이 $[0, 255]$ 범위를 잘 활용하도록 학습한다. 이 작업 이후 이어지는 활성화 함수는 값을 추가로 제한하는 역할을 하지 않고, 그 기능이 이미 양자화 과정에서 uint8 로 변환될 때 내포된 범위 제한에 포함된다.

- 즉, 활성화 함수는 **실질적으로 아무런 작업을 하지 않고** 추가적인 조정 없이 값의 범위를 자연스럽게 제한한다. 이 방식은 연산 효율성을 높이고 정확도 유지에 중요한 역할을 한다.

3. Training with simulated quantization

양자화된 네트워크를 훈련하는 일반적인 방법은 부동 소수점으로 훈련한 뒤 가중치 결과를 양자화하는 것이다. 이러한 접근법은 큰 모델에서 효율적으로 잘 동작하나, 작은 모델에서는 정확도가 떨어지는 것을 확인했다. 일반적으로 훈련 후 양자화 하는 방식(Post-Training Quantization)의 실패 이유는 다음과 같다.

- 1) 출력 채널마다 **가중치 범위가 큰 차이**(100 배 이상)를 갖는다. (동일한 레이어의 모든 채널은 동일한 해상도로 양자화해야 하므로 범위가 작은 채널의 가중치는 상대 오차가 훨씬 더 크다.)

- 2) 양자화 후 남은 모든 가중치를 덜 정밀하게 만드는 **이상치(outlier) 가중치 값이 존재한다.**

훈련의 정방향 통과에서 양자화 효과를 시뮬레이션하는 접근 방식을 제안한다. 역전파는 평소처럼 동작하며 모든 가중치와 편향은 부동 소수점으로 저장되어 있다. 정방향 전파는 양자화된 추론으로 동작한다.

- 가중치들은 입력과 합성곱(convolve)되기 전에 양자화된다. 배치 정규화를 사용하는 경우, 배치 정규화 파라미터는 양자화 전의 가중치로 **"접힌(folded into)"** 것이다.

- 활성화 값은 추론하는 그 시점에 양자화 된다. 예를 들어, 활성화 함수가 Convolution 이나 FC 레이어의 출력에 적용된 이후, 또는 bypass connection 이 ResNets 같이 여러 레이어의 출력을 추가하거나 연결한 후에 이루어진다.

Folded Batch Normalization (FBN)

배치 정규화(BN)의 파라미터를 이전 레이어(주로 합성곱이나 완전 연결층)의 가중치와 편향에 통합하는 기법으로, 추론 단계에서 BN 연산을 제거하여 계산 효율성을 높일 수 있다.

1. 추론 단계의 비효율성

학습 중에는 BN 이 효과적이지만, 추론 단계에서는 고정된 평균과 분산을 사용하기에 BN 은 추가적인 계산 부담을 초래한다. 따라서, 이전 레이어의 가중치와 편향에 병합(folding)하여 효율성을 높인다.

2. 동작 방식

$$W' = W \times \frac{\gamma}{\sqrt{\sigma^2 + \epsilon}}, \quad b' = \beta - \frac{\gamma \times \mu}{\sqrt{\sigma^2 + \epsilon}}$$

이렇게 하면 BN 레이어 없이도 동일한 결과를 얻을 수 있으므로, 추론 단계에서 BN 을 제거할 수 있다.

각각의 레이어에서 양자화는 양자화 레벨(Quantization Levels)의 수와 클램핑 범위(clamping range)에 의해 매개변수화 되며, 다음과 같이 정의된 양자화 함수 q 를 point-wise 로 적용하여 수행된다.

$$\text{clamp}(r; a, b) := \min(\max(r, a), b)$$

$$s(a, b, n) := \frac{b - a}{n - 1}$$

$$q(r; a, b, n) := \left\lfloor \frac{\text{clamp}(r; a, b) - a}{s(a, b, n)} \right\rfloor s(a, b, n) + a \quad (12)$$

- $\text{clamp}(r; a, b) - a$: r 값을 $[a, b]$ 로 클램핑하고 시작점 a 를 기준으로 이동.
- $\frac{\text{clamp}(r; a, b) - a}{s(a, b, n)}$: 이동한 값을 스케일 $s(a, b, n)$ 로 나누어 정수 수준으로 변환.
- $\lfloor \cdot \rfloor$: 가장 가까운 정수로 반올림.
- $s(a, b, n) + a$: 다시 스케일을 곱하고 a 를 더하여 원래 범위로 복원.

r 은 양자화 할 실수 값이며, $[a; b]$ 는 양자화 범위, n 은 양자화 레벨의 수, 그리고 $\lfloor \cdot \rfloor$ 는 가장 가까운 정수로의 반올림을 나타낸다. n 은 8-bit 양자화를 위해 256 으로 모든 레이어에 대해 고정된다.

3.1. Learning quantization ranges

양자화 범위(Quantization ranges)는 가중치 양자화와 활성화 양자화에 대해 각각 다르게 취급된다.

가중치의 경우 기본 아이디어는 단순히 $a := \min w$, $b := \max w$ 로 설정하는 것이다. 여기에 약간의 조정을 적용하여, 한 번 int8 값으로 정량화된 가중치가 $[-127, 127]$ 범위 내에서만 적용되고 -128 값은 절대 취하지 않도록 한다. 이는 상당한 최적화 기회를 제공한다.

활성화의 경우 범위가 네트워크로 들어가는 입력에 의존한다. 범위를 추정하기 위해 훈련 중 활성화에서 보여지는 $[a; b]$ 범위를 수집하였다. 이후 지수 이동 평균(EMA)을 통해 이를 집계한다. 평활화(smoothing) 파라미터는 1 에 가까워서 관찰된 범위가 수천 개의 훈련 단계에서 평활화되도록 한다.

EMA 업데이트 활성화 범위가 급격하게 변화할 때 상당한 지연이 발생한다는 점을 고려할 때, 훈련 시작 시 활성화 양자화를 완전히 비활성화하는 것이 유용하다는 것을 발견하였다. 이를 통해 네트워크는 활성화 양자화 범위가 더 안정적인 상태에 진입할 수 있다.

Exponential Moving Averages (EMA)를 이용한 범위 추정

- 훈련 중 관찰된 활성화 값의 최소값과 최대값을 이용해 범위를 추정한다.
- 새로운 범위 $\coloneqq \alpha \cdot \text{이전 범위} + (1 - \alpha) \cdot \text{현재 관찰된 값}$
- α 는 EMA의 평활화(smoothing) 계수로, 1에 가까운 값을 사용해 관찰된 범위가 천천히 변화하도록 만든다. 이상치나 급격한 범위 변화로 인한 불안정성을 줄일 수 있다.

초기 단계에서 활성화 양자화를 비활성화하는 이유

- 훈련 초기에 활성화 범위가 불안정할 수 있다.
- EMA가 안정적인 범위를 학습할 시간이 필요하다.

두 경우 모두 $[a; b]$ 범위는 양자화 이후 정수 $z(a, b, n)$ 이 값 0.0으로 정확하게 표현될 수 있도록 조금씩 움직인다. 결과적으로 학습된 양자화 파라미터는 아래와 같이 매핑된다.

$$S = s(a, b, n), \quad Z = z(a, b, n) \quad (13)$$

3.2. Batch Normalization folding

ResNet depth	50	100	150
Floating-point accuracy	76.4%	78.0%	78.8%
Integer-quantized accuracy	74.9%	76.6%	76.7%

Table 4.1: ResNet on ImageNet: Floating-point vs quantized network accuracy for various network depths.

Scheme	BWN	TWN	INQ	FGQ	Ours
Weight bits	1	2	5	2	8
Activation bits	float32	float32	float32	8	8
Accuracy	68.7%	72.5%	74.8%	70.8%	74.9%

Table 4.2: ResNet on ImageNet: Accuracy under various quantization schemes, including binary weight networks (BWN [21, 15]), ternary weight networks (TWN [21, 22]), incremental network quantization (INQ [33]) and fine-grained quantization (FGQ [26])

4. Experiments